Computer Organization & Design实验与课程设计

Lab06 缓存设计

Ma De (马德)
made@zju. edu. cn
2022

Course Outline

- 一、实验目的
- 二、实验环境
- 三、实验目标及任务

实验目的

- 1. 理解高速缓存的基本概念和作用
- 2. 掌握缓存的组织结构和映射方式、替换策略
- 3. 理解缓存的工作原理、命中率和一致性问题
- 4. 设计缓存的控制器模块和存储模块

2022/2/10

实验环境

□实验设备

- 1. 计算机(Intel Core i5以上,4GB内存以上)系统
- 2. Sword 2.0/Sword 4.0开发板
- 3. VIVADO 2017.4及以上开发工具

□材料

无

实验目标及任务

■目标:熟悉数据缓存的工作原理,了解存储单元的组织结构,掌握缓存控制器的设计方法,设计并测试两路组关联Cache

■任务1:数据缓存模块的设计(---two-way set associate cache)

■任务2: 数据缓存模块的仿真验证

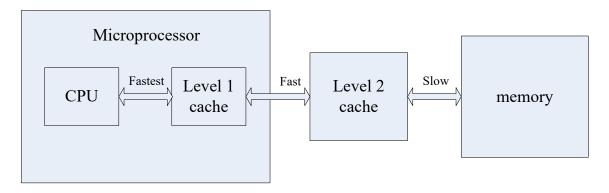
2022/2/10 Chapter 6

缓存的原理介绍

2022/2/10 Chapter 6 6

Cache的基本概念

- □ Cache又叫高速缓冲存储器,位于CPU与内存之间 ,是一种特殊的存储器子系统。
- □目前比较常见的是两极cache结构,即cache系统由一级高速缓存L1 cache和二级高速缓存L2 cache组成,L1 cache通常又分为数据cache(D-Cache)和指令cache(I-Cache),它们分别用来存放数据和执行这些数据的指令。



2022/2/10

Cache的作用

- □ Cache的作用就是为了提高CPU对存储器的访问速度。
- □ 电脑的内存是以系统总线的时钟频率工作的,这个频率通常也就是CPU的外频。但是,CPU的工作频率(主频)是外频与倍频因子的乘积。因此,内存的工作频率就远低于CPU的工作频率了。导致的直接结果是:CPU在执行完一条指令后,常常需要"等待"一些时间才能再次访问内存,极大降了CPU工作效率。

-----cache 诞生!

Cache的工作原理

□ CPU运行程序是一条指令一条指令地执行的,而且 指令地址往往是连续的,即CPU在访问内存时,在 较短的一段时间内往往集中于某个局部,这时候可 能会碰到一些需要反复调用的子程序。系统在工作 时,可把这些活跃的子程序存入比主存快得多的 cache 中。

时间相关性(temporal locality):如果一个数据现在被访问了,那么以后很有可能也会被访问;

空间相关性(spatial locally):如果一个数据现在被访问了,那么它周围的数据在以后可能也会被访问

2022/2/10 Chapter 9

Cache的工作原理

□ CPU在访问内存时,首先判断所要访问的内容是否在cache中,如果在,则称为命中(hit),此时CPU直接从cache中调用该内容;否则称为未命中(miss),CPU会通过cache对主存中的相应内容进行操作。

2022/2/10 Chapter 9 10

□ Cache与主存之间可以采取的地址映射方式有以下三种:

■全相联映射方式

- ■直接相联映射方式
- ■组相联映射方式

2022/2/10 Chapter 9

11

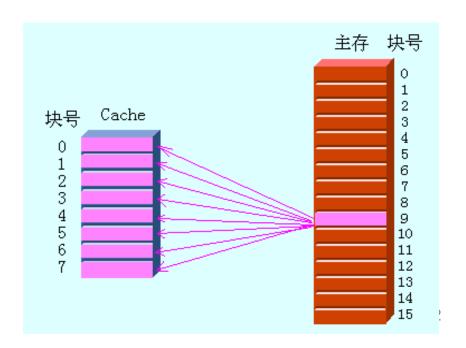
□全相联方式

地址映射规则: 主存的任意一块可以映射到cache中的任意一块

- (1) 主存与cache分成相同大小的数据块。
- (2) 主存的某一数据块可以装入cache的任意一块空间中。

优点:命中率比较高,cache存储空间利用率高。

缺点:速度低,成本高,访问相关存储器时,每次都要与全部内容比较。



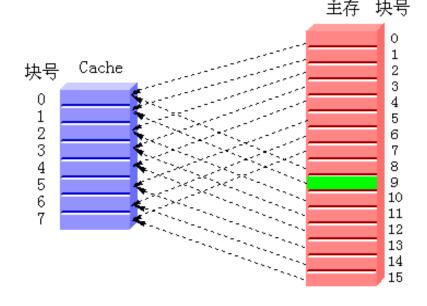
□直接相联方式

地址映射规则: 主存储器中一块只能映射到cache的一个特定的块中。

- (1)主存与cache分成相同大小的数据块。
- (2)主存容量应是cache容量的整数倍,将主存空间按cache的容量分成区
 - ,主存中每一区的块数与cache的总块数相等。
- (3)主存中某区的一块存入cache时只能存入缓存中块号相同的位置。

优点:地址映射方式简单,数据访问时,只需检查区号是否相等即可, 因而可以得到比较快的访问速度,硬件设备简单。

缺点:替换操作频繁,命中率比较低。



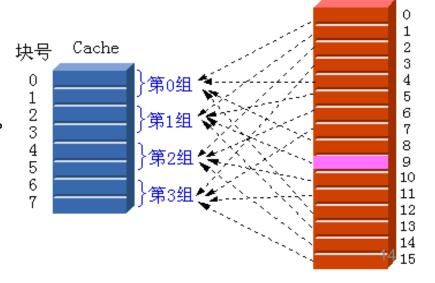
本实验采用此方式

□ 组相联映射方式 地址映射规则:

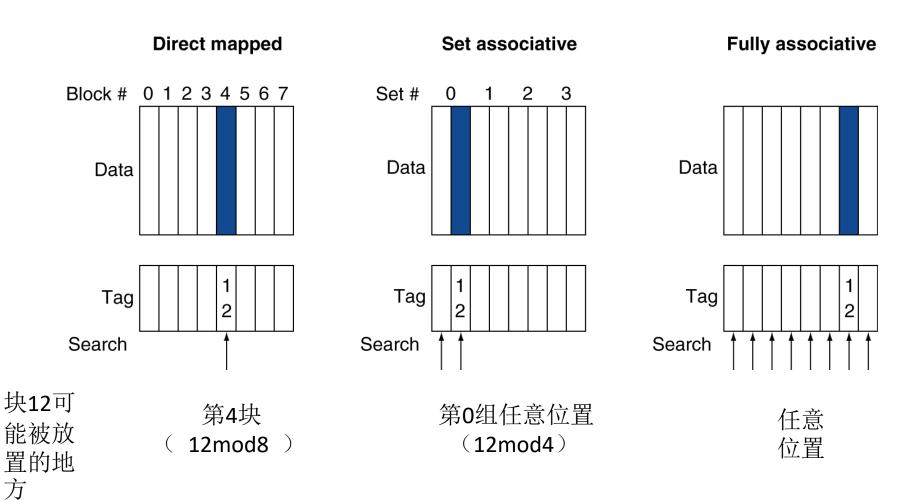
- (1) 主存和cache按同样大小划分成块。
- (2) 主存和cache按同样大小划分成组。
- (3) 主存容量是cache容量的整数倍,将主存空间按cache区的大小分成区,主存中每一区的组数与cache的组数相同。
- (4) 当主存的数据调入cache时,主存与cache的组号应相等,也就是各区中的某一块只能存入cache的同组号的空间内,但组内各块地址之间则可以任意存放, 即从主存的组到cache的组之间采用直接映射方式; 在两个对应的组内部采用全相联映射方式。

优点: 块的冲突概率比较低, 块的利用率大幅度提高, 块失效率明显降低。

缺点:实现难度和造价要比直接映射方式高。



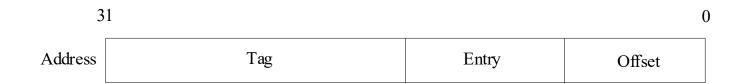
块号



2022/2/10

Cache的组织结构

- □ 块(block):块是cache与主存的传输单位。
- □路(way):路是组相联映射方式的cache结构中的基本存储单位,每一路存储一个块的数据。
- □ 组(set/entry):组是组相联映射方式的cache对块进行管理的单位。
- □区(tag):块的地址对应的主存储器中的区。
- □ 块内偏移地址(offset):用来标示块内一个字(节)的地址。
- □ 组相联映射方式下主存储器的地址空间由,区,组和块内偏 移地址组成:

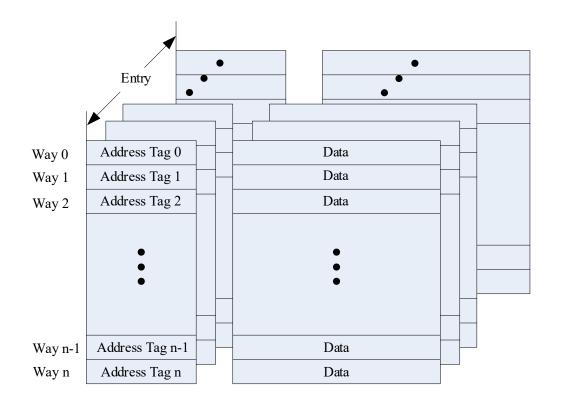


2022/2/10 Chapter 9

16

Cache的组织结构

□组相联映射方式下cache的内部结构。



2022/2/10 Chapter 9 17

Cache的替换算法

□ Cache可以采用的替换算法主要有以下几种

- · 先入后出(FILO)算法
- 随机替换(RAND)算法
- · 先入先出(FIFO)算法
- 近期最少使用(LRU)算法



所要解决的问题:当新调入一块,而Cache 又已被占满时,替换哪一块?

2022/2/10 Chapter 9 18

Cache的替换算法

- □ 随机(RAND)法是随机地确定替换的存储块。设置一个随机数产生器,依据所产生的随机数,确定替换块。这种方法简单、易于实现,但命中率比较低。
- □ 先进先出(FIFO)法是选择那个最先调入的那个块进行替换 。当最先调入并被多次命中的块,很可能被优先替换,因 而不符合局部性规律。这种方法的命中率比随机法好些, 但还不满足要求。
- □ 近期最少使用(LRU)法是依据各块使用的情况,总是选择 那个最近最少使用的块被替换。这种方法比较好地反映了 程序局部性规律,命中率最高。

2022/2/10 Chapter 9

19

Cache的性能评估

- □ 提高cache的性能也就是要降低主存的平均存取时间 主存平均存取时间=命中时间+未命中率*未命中惩罚
- □ 提高cache的性能有以下三种方法:减少命中时间,减少未命中率,减少未命中惩罚。

影响命中率的硬件因素主要有以下四点:

- Cache的容量。
- Cache与主存储器交换信息的单位量(cache line size)。
- Cache的组织方式
- Cache的替换算法

2022/2/10 Chapter 9

20

Cache的一致性问题

- 在采用cache的系统中,同样一个数据可能既存在于cache 中,也存在于主存中,两者数据相同则具有一致性,数据 不相同就叫做不一致。
- Cache主要有两种写策略写直达法(write through)和写回 法(write back)



2022/2/10 Chapter 9 21

Cache的一致性问题

□ 写直达法(write through)

方法: 在对cache进行写操作的同时,也将内容写到主存中。

优点:可靠性较高,操作过程比较简单。

缺点: 写操作速度得不到改善, 与写主存的速度相同。

□ 写回法 (write back)

方法: 在CPU执行写操作时,只写入cache,不写入主存。

优点:速度较高。

缺点:可靠性较差,控制操作比较复杂。

2022/2/10 Chapter 9

■任务1: 数据缓存模块的设计

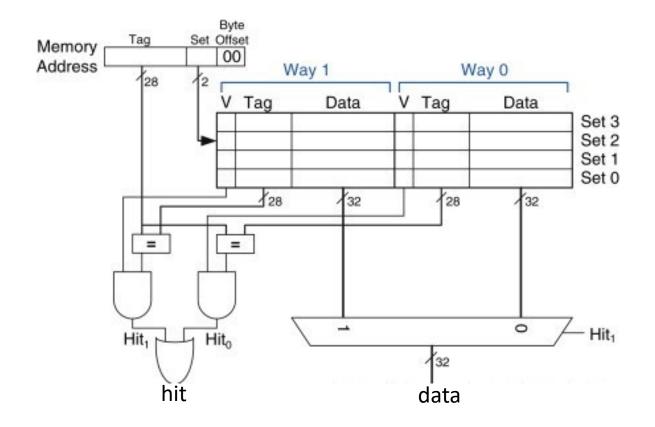
-----Cache存储体 (cache memory)

-----Cache控制器(cache controller)

2022/2/10 Chapter 6 23

Cache设计实现

■ 如图,为两路四组的组织结构:



2022/2/10 Chapter 9 24

Cache设计实现 ■ two-way set associate cache

■ Cache的一行构成(cache line)



- •Tag: 标签位用于比较在way1和way0两路中,哪一个cache块存了我们的目的数据
- •data block: 数据位用来存储(内存和cache交换的数据块)目标tag的数据块。
- •v: 有效位用来 表示该cache块是否有效。

2022/2/10 Chapter 9 25

Cache设计实现 ■ two-way set associate cache

■ cache的数据对应的内存地址



- •Block offset: 对于内存地址而言,其后block offset个字节的数据会构成一个和cache做数据交换的块,即cache块的大小。
- •index: 对于内存地址而言,其应该被映射到cache里的哪一组,故该部分的位数代表的是整个cache能容纳多少组;上图,2路组相连,其中的MemoryAddress里的set是2位,那么这个内存地址就可以根据set的两位去找到自己在cache中对应的组是哪一组,如:当set的两位为10时,那么对应到第3组set2。
- •tag: 在使用index选出cache位于哪一组后去比较具体的cache块位于哪一路。

2022/2/10

Cache设计实现

two-way set associate cache

0

0

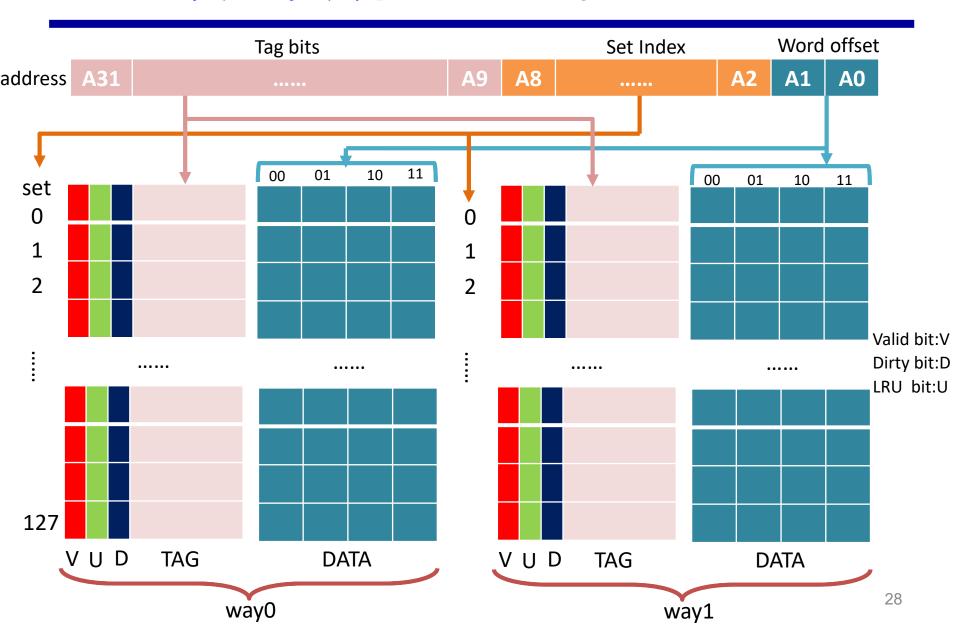
- ■本实验所实现的Data Cache功能要求:
 - two-way set associate cache
 - Write Back
 - Write Allocate
 - Block size is four words(16bytes or 128bits)
 - Cache size is 4KiB
 - Replacement Policy: Least Recently Used





Cache设计实现

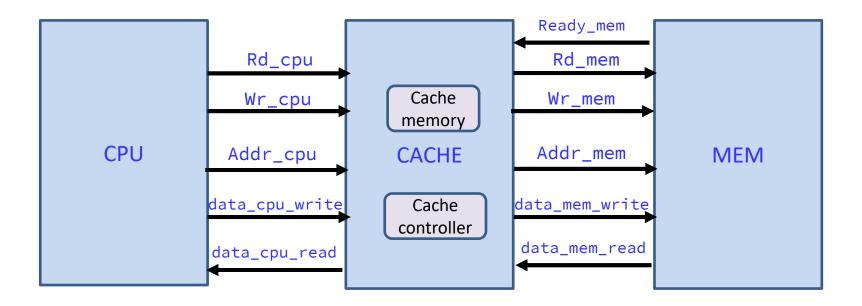
two-way set associate cache



Cache设计实现 ■ two-way set associate cache

29

Data Cache与·CPU、Memory接口:



2022/2/10 Chapter 9

Cache设计实现 ■ two-way set associate cache

■ Data Cache基本参数:

Parameter	Value	Unit
Size of Cache	4	КВ
Associativity	2-way	-
NUM of Sets	128	-
Blocks/Cache line	4	words
Address width	32	bits
Data width	32	bits
TAG width	23	bits
Index width	7	bits
Word offset	2	bits
Valid width	1	bit
Dirty width	1	bit
LRU width	1	bit

2022/2/10 Chapter 9 30

Cache设计实现 ■ Cache Memory

- Cache Memory由Cache line构成,包含存储的数据字段,标签字段以及是否有效位;而本实验中还需设置脏位和LRU标志位。
- 由前two-way set associate cache的示意图得知,依据存储地址的Index索引到Cache中具体的哪一组,得到两路中的两个Cache line;而后通过Tag比较确定最终选择line;最后由Block offset定位所需数据。
- 此处将TAG和Data部分开存储,可以同时并行访问TAG Ram, Data Ram。

2022/2/10

Cache设计实现 ■ Cache Memory:Data_ram0/1

```
module Data_ram0(
        input wire clk, // clock
        Input wire en, // enable
        input wire [Index_width-1:0] addr, // address
        input wire [Block_width-1:0] din, // data write in
        output reg [Block_width-1:0] dout, // data read out
        );
```

2022/2/10 Chapter 9

32

Cache设计实现 ■ Cache Memory:Data_ram0/1

```
//cache line memory: data for way0
reg [Block_width-1:0] cache_data [0:NUM_of_sets-1];
//memory initial
Initial begin
         $readmemh(".....", cache_data);
end
//Read and Write data to Cache
                                         0
dout <= cache_data[addr];</pre>
cache_data[addr] <= din;</pre>
   2022/2/10
                                                                       Chapter 9
                                                                                   33
```

Cache设计实现 ■ Cache Memory:Tag_ram0/1

```
module Tag_ram0(
    input wire clk, // clock
    Input wire en, // enable
    input wire [Index_width-1:0] addr, // address
    input wire [TAG_width+V+U+D-1:0] din, // data write in
    output reg [TAG_width+V+U+D-1:0] dout, // data read out
    );
```

2022/2/10 Chapter 9

34

Cache设计实现 ■ Cache Memory:Tag_ram0/1

```
//cache line memory: tag,V,U,D for way0
reg [TAG_width+V+U+D-1:0] cache_TAG [0:NUM_of_sets-1];
//memory initial
Initial begin
         $readmembh(".....", cache_data);
end
//Read and Write TAG to Cache
                                         0
dout <= cache_TAG[addr];</pre>
cache_TAG[addr] <= din;</pre>
   2022/2/10
                                                                     Chapter 9
                                                                                  35
```

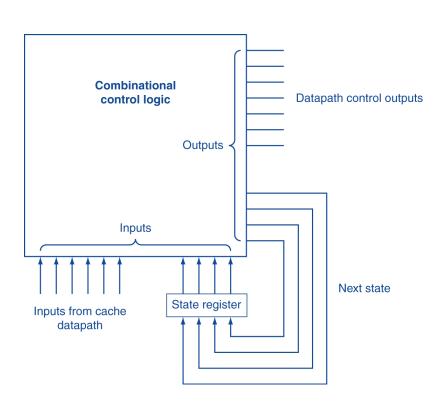
Cache设计实现 ■ Cache Controller

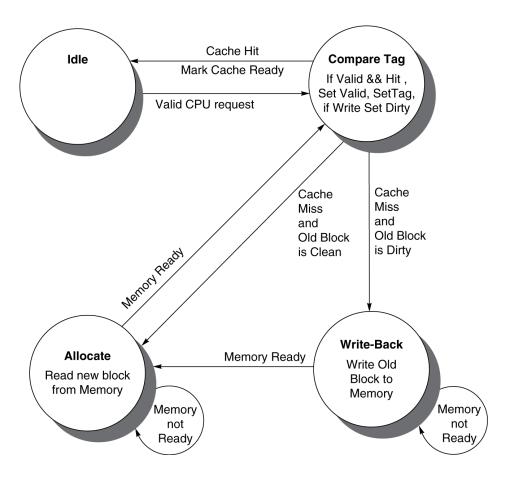
- Cache控制采用FSM实现。
- 实现标签比较,检测读写命中与否。
- 实现Cache的数据更新,当miss后采用LRU完成数据替换。
- ■实现Mem的数据更新,当write miss后采用Write Back,被改写的数据块在被替换出cache时写回到Mem。同时实现Write Allocate。

2022/2/10

Cache设计实现 ■ Cache Controller

■ Cache控制采用FSM实现





2022/2/10 Chapter 9 37

Cache设计实现 ■ Cache Controller

■ Cache控制部分采用FSM实现

```
always@(posedge clk or posedge rst)
if(rst)
  state<=IDLE;
else
  state<=next state;
always@(*)
case(state)
  IDLE:if(cpu req valid)
     else
       next state=IDLE;
                                 //若hit
  CompareTag:if(hit)
        else
          next state=Allocate;
```

```
Allocate:if(mem_ready)
         next state=CompareTag;
       else
         next state=Allocate;
  WriteBack:if(mem ready)
  default:next state=IDLE;
Endcase
```

Cache设计实现 ■ Cache.v 顶层端口

■ 顶层完成存储体的调用和控制器模块模块的实现 module cache(

```
input wire clk, // clock
     input wire rst, // reset
     input wire [31:0] data_cpu_write, // data write in
     input wire [31:0] data_mem_read, // data read in
     input wire [31:0] addr_cpu, // cpu addr
               wr_cpu, // cpu write enable
     input wire
                   rd_cpu, // cpu read enable
     input wire
               ready_mem, // memory ready
     input wire
                    wr_mem, // memory write enable
     output reg
                    rd_mem, // memory read enable
     output reg
     output reg [31:0] data_mem_write, // data to mem
     output reg [31:0] data_cpu_read, // data to cpu
     output reg [31:0] addr_mem, // memory addr
2022/2/10
```

Cache设计实现 ■ Cache.v 顶层端口

顶层完成存储体的调用和控制器模块模块的实现

```
// Cache Controller State Machine and Logic
                                                                   Way1的存储
always@(posedge clk or posedge rst)
                                                                   例化过程相
if(rst)
  state<=IDLE;
else
  state<=next state;
                                            // Instantiation of Tag RAM for Way 0
                                                          t0 (.clock(clock),
                                            Tag ram0
                                                             .addr(index),
                                                               .din(wtag0),
// Instantiation Data RAM for Way 0
                                                               .en(ent0),
Data_ram0 d0 (.clock(clock),
                                                               .dout(rtag0)
                .addr(index),
                .din(wdata),
                .en(en0),
  2022/2/10
                                                                      Chapter 9
                .dout(rdata0));
```

■任务2: 数据缓存模块的仿真验证

2022/2/10 Chapter 6 41

Cache仿真验证

■本实验所实现的Data Cache测试要求:

- Read hit
- Write hit
- Read miss
- Write miss

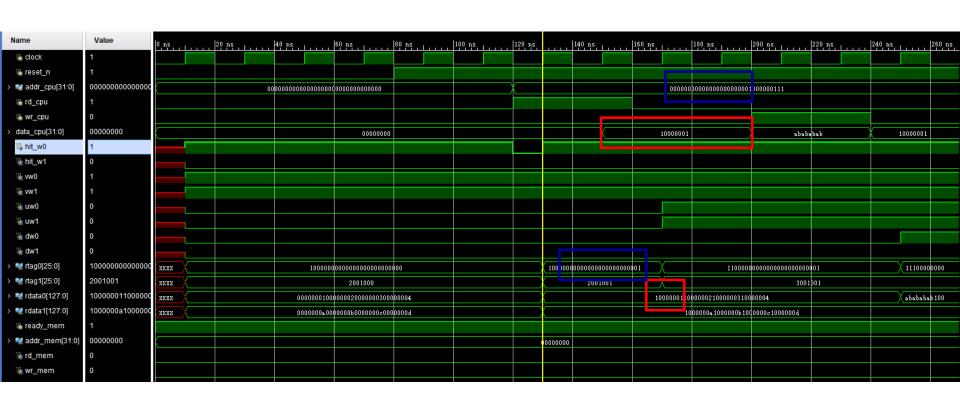


2022/2/10 Chapter 9 42

Cache仿真测试 ■ Cache_tb.v

```
module cache_tb();
//read hit
rd_cpu = 1'd1;
addr_cpu = 32'h00000207;
// Write to same location
wr_cpu = 1'd1;
wcpu = 32'habababab;
addr_cpu = 32'h00000207;
// Read from same location to check updated data
rd_cpu = 1'd1;
addr cpu = 32'h00000207;
```

Read hit at 0x000000207



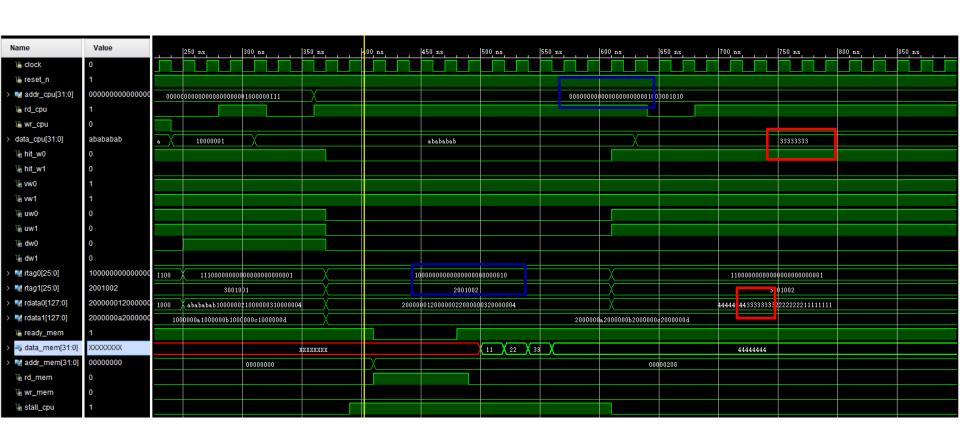
Write hit at 0x000000207



Cache仿真测试 ■ Cache_tb.v

```
//Read Miss with dirty bit 0 policy check, reads data from Main Memory
rd_cpu = 1'd1;
addr cpu = 32'h0000020A;
dmem= 32'h11111111;
delay
dmem= 32'h22222222;
                                                          read miss with
                                                            dirty bit 1
delay
                                                           additionally
dmem= 32'h33333333;
delay
dmem= 32'h4444444;
// Read from same location to check updated data
rd_cpu = 1'd1;
addr cpu = 32'h0000020A;
```

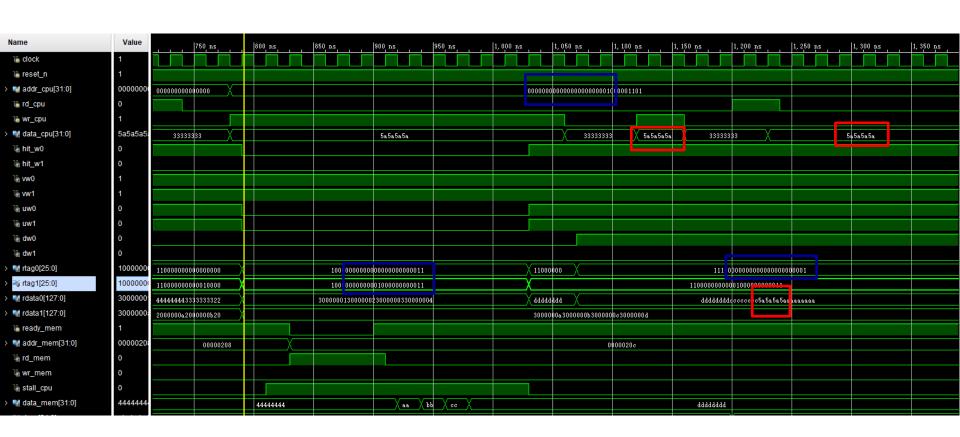
Read miss at 0x00000020A and after read from RAM, read hit



Cache仿真测试 ■ Cache_tb.v

```
//Write Miss with dirty bit 0 policy check, reads data from Main Memory
wr cpu = 1'd1;
wcpu=32'h5a5a5a5a;
addr_cpu = 32'h0000020D;
                                                          write miss with
                                                            dirty bit 1
dmem= 32'hAAAAAAAA;
                                                            additionally
delay
dmem= 32'hBBBBBBBB;
                                // write the same address again, write hit
delay
                                wr cpu = 1'd1;
                                wcpu=32'h5a5a5a5a;
dmem= 32'hCCCCCCC;
                                addr cpu = 32'h0000020D;
delay
dmem= 32'hDDDDDDDD;
                                // Read from same location to check the writing data
                                rd cpu = 1'd1;
                                addr cpu = 32'h0000020D;
```

Write miss at 0x00000020D and after write allocate, write hit



思考题

□实验只设计实现数据缓存,若实现指令缓存,设计方法是否一样?指令缓存也会存在写回、写分派现象吗?指令缓存的内容如果需要修改,如何操作?

□ 带缓存的流水线CPU如何实现,当发生缺失的情况时CPU应该如何应对?



2022/2/10 Chapter 9 51